

Mémoire de M2

Master MIAGE (apprentissage)

Le challenge de l'application du Transfer Learning sur la reconnaissance des signes de l'alphabet Français

Entreprise d'accueil : Crédit Agricole Technologies et Services (CATS)
Mémoire réalisé du 01 septembre 2023 au 01 juin 2024

présenté et soutenu par

CHEBAH Amine

le 1er juin 2024

Jury de la soutenance

M. François Delbot,
Mme. Sonia Sadaoui,
Mme. Laura Valery,

Maître de conférences
Maître de conférences
Cartographe

Responsable du master
Tuteur enseignant
Maître d'apprentissage

Remerciements

Je tiens à exprimer ma profonde gratitude à toutes les personnes qui ont contribué à la réalisation de ce mémoire de recherche. Tout d'abord, je tiens à remercier ma tutrice pour son soutien constant, ses conseils éclairés. Je suis reconnaissant envers mes enseignants et mes camarades pour leurs encouragements, leurs discussions stimulantes et leurs commentaires constructifs. Je souhaite également remercier ma maître d'apprentissage pour m'avoir accompagné tout le long de cette année. Enfin, je suis reconnaissant envers toutes les personnes dont les travaux ont contribué à l'avancement des connaissances de l'application du Transfer Learning sur la reconnaissance des signes. Leurs recherches et leurs idées ont été une source d'inspiration pour mon propre travail.

Résumé

Abstract

Ce mémoire explore l'efficacité du transfert d'apprentissage dans la reconnaissance de l'alphabet de la Langue des Signes Française (LSF), où les ensembles de données sont souvent limités. L'objectif principal est de démontrer comment l'utilisation de modèles pré-entraînés peut améliorer significativement les performances sur des tâches spécifiques avec des données rares. En utilisant des modèles pré-entraînés sur des ensembles de données larges et diversifiés, puis en les affinant sur des données spécifiques à la LSF, nous visons à optimiser la précision et la robustesse de la reconnaissance des signes.

Nous avons mené des expériences avec trois modèles différents : un réseau de neurones convolutif (CNN) personnalisé, deux réseaux de neurones pré-entraînés : VGG16 et MobileNetV2. Les modèles ont été entraînés et évalués sur un ensemble de données de signes de l'alphabet LSF, avec des techniques d'augmentation des données pour réduire les biais et améliorer la généralisation.

Les résultats montrent un avantage clair de l'utilisation du transfert d'apprentissage. Le modèle CNN a atteint une précision de 80% avec une perte de 2,46 sur des images de 64x64, VGG16 a atteint 95% de précision avec une perte de 0,14 sur des images de 64x64, et MobileNetV2 a surpassé les autres avec une précision remarquable de 99% et une perte de 0,02 sur des images de 224x224. Ces résultats valident l'hypothèse selon laquelle le transfert d'apprentissage est une stratégie efficace pour les tâches de reconnaissance des signes avec des données limitées, ouvrant la voie à des améliorations futures et à des applications dans les systèmes d'interprétation de la langue des signes en temps réel.

Table des matières

1	Introduction au Transfer Learning et la Reconnaissance du Langage des Signes	6
1.1	Contexte et importance de la Reconnaissance du Langage des Signes . .	6
1.2	Méthodologie de recherche	7
1.2.1	Objectifs et questions de recherche	7
1.2.2	Critères de recherche	8
1.2.3	Termes clés et requêtes	9
1.2.4	Observations sur les articles obtenues	9
1.2.5	Screening	11
1.3	Objectif du mémoire	11
2	Revue technologique portée sur la reconnaissance du langage des signes	13
2.1	Domaines d'application et tâches liées à la langue des signes	13
2.2	Les avancées technologiques	15
2.2.1	Les réseaux CNN	15
2.2.2	Les réseaux RNN et Transformers	16
2.3	Critique et perspectives : analyse critique des modèles actuels	17
3	Le Transfer Learning : Théorie et application	18
3.1	Fondements du transfer learning	18
3.1.1	Les différents types de Transfer Learning	18
3.1.2	Les méthodes et stratégies pour aborder le Transfer Learning . .	19
3.1.3	Défis liés à l'application du Transfer Learning	19
3.2	Exemples d'application et élargissement : la polyvalence et l'applicabilité du transfer learning	20
4	Application du transfer learning à la reconnaissance du langage des signes	21
4.1	Études de cas : Analyse des études existantes qui ont employé l'apprentissage par transfert dans ce domaine	21
4.1.1	Application du Transfer Learning à la reconnaissance de l'alphabet de la langue des signes Arabe	21
4.1.2	Reconnaissance d'une sélection de mots signés en indien en temps réel	22
4.2	Performances et limitations de ces cas d'études	23
5	Perspectives actuelles et futures	25
5.1	Innovations récentes et études de cas	25
5.2	Potentiel d'amélioration et directions de recherche	26

6	Expérimentation	28
6.1	Constitution du dataset	28
6.1.1	Collection des Données	28
6.1.2	Prétraitement des Données	30
6.2	Augmentation des données	31
6.2.1	Techniques d'Augmentation des Données	31
6.2.2	Rôle de l'augmentation des données	32
6.3	Sélection des modèles	33
6.3.1	Choix des modèles	33
6.3.2	Justification des Choix des couches, des hyperparamètres	34
6.3.3	Apprentissage par transfert :	34
6.4	Entraînement et validation des modèles	35
6.4.1	Configuration de l'Entraînement	35
6.4.2	Processus d'Entraînement	36
6.5	Évaluation, validation et résultat	37
6.5.1	Évaluation du Modèle	37
6.5.2	Résultats obtenus sur l'ensemble de test	38
6.5.3	Visualisation des performances	41
6.6	Application en temps réel	47
6.6.1	Description de l'interface utilisateur avec Streamlit	47
6.6.2	Intégration du modèle pour la prédiction en temps réel	48
6.6.3	Traitement des images en temps réel	48
6.6.4	Prédiction du signe et affichage des résultats en temps réel	48
6.6.5	Résultat en utilisant l'Application	48
7	Conclusion et perspectives	50
	Bibliographie	51
	Webographie	53
8	Annexes	55
.1	Code Validation croisée	55

Chapitre 1

Introduction au Transfer Learning et la Reconnaissance du Langage des Signes

1.1 Contexte et importance de la Reconnaissance du Langage des Signes

Les langues des signes sont des outils de communication vitaux qui permettent aux personnes sourdes et malentendantes d'interagir avec le monde qui les entoure. Contrairement aux langues parlées qui reposent sur des composants auditifs et verbaux, les langues des signes utilisent des mouvements manuels, des expressions faciales et des gestes corporels pour transmettre du sens, incarnant ainsi une riche variété de structures linguistiques propres aux cultures sourdes du monde entier. Ce mode de communication n'est pas une langue universelle mais comprend de nombreuses langues distinctes, chacune avec son propre lexique et ses nuances culturelles. La reconnaissance et la traduction des langues des signes par des moyens informatiques offrent la possibilité de combler les écarts de communication, d'améliorer l'accessibilité et de favoriser l'inclusion, soulignant l'importance de faire progresser la technologie dans ce domaine. L'organisation des nations unies (ONU) [WEB 1] indique qu'il existe plus de 70 millions de sourds dénombrés dans le monde entier, l'ensemble de ces malentendants utilisent collectivement plus de 300 langues des signes différentes. D'après la Fédération Nationale des Sourds de France (FNSF) [WEB 2], on dénombre environ 300 000 sourds en France dont seulement le tiers (soit 100 000) utilise couramment la LSF. L'avancée des différentes technologies permettant de faciliter l'apprentissage et la compréhension de ces différentes langues est donc primordiale en France et dans le monde plus généralement.

L'article de Noha Sarhan et Simone Frintrop[11] examine le Transfer Learning (TL) et la reconnaissance du langage des signes, mettant en lumière leur importance pour la communication avec les personnes sourdes et malentendantes. Il souligne les défis techniques posés par la diversité des langues des signes et la complexité des gestes.

Le transfer learning est présenté comme une méthode prometteuse pour améliorer la reconnaissance du langage des signes. Cette technique permet d'exploiter les connaissances acquises dans un domaine pour améliorer les performances dans un autre domaine, ce qui est particulièrement utile pour traiter la variété des langues des signes.

Le travail de Razieh Rastgoo et al. [2] traite de la complexité de la reconnaissance du langage des signes dans le domaine de la computer vision. Il offre une vue d'ensemble sur les méthodes isolées de reconnaissance du langage des signes (ISLR) et sur les méthode continue de reconnaissances des signes (CSLR), discutant des aspects tels que les modalités d'entrée (RGB, profondeur des mains dans l'image...) les paramètres de la langue des signes modélisés (forme des mains, orientation, éléments non manuels...), les méthodes de fusion (d'éléments venant de différentes sources), et le transfer learning. Chacun de ces éléments joue un rôle crucial dans l'amélioration de la précision des systèmes de reconnaissance.

Enfin, l'article [2] met en avant l'importance des ensembles de données de référence pour l'ISLR et CSLR et évalue les performances des méthodes les plus avancées. En explorant ces aspects et en détaillant les progrès et défis actuels, l'article offre des perspectives sur les développements futurs dans le domaine, soulignant son importance pour améliorer l'accessibilité et la communication pour la communauté sourde et mal-entendante.

1.2 Méthodologie de recherche

1.2.1 Objectifs et questions de recherche

Malgré le rôle crucial des langues des signes dans les communautés sourdes, de nombreuses langues des signes sont considérées comme étant à faibles ressources dans le contexte de la recherche informatique (Machine learning et deep learning), caractérisées par une rareté de jeux de données annotés et d'études linguistiques. Cette limitation pose des défis importants pour le développement de systèmes précis et fiables de reconnaissance et de traduction des langues des signes, en particulier pour les langues en dehors des exemples largement étudiés comme la Langue des Signes Américaine (ASL). C'est là que réside le potentiel de l'apprentissage par transfer learning - un apprentissage basé sur les connaissances acquises par un modèle pré-entraîné sur un dataset extrêmement riche pour une tâche similaire à celle que l'on souhaite réaliser où les ressources sont généralement pauvres pour cette dite tâche.

Voici les différentes questions de recherches que nous nous sommes posées :

— **Quels types de travaux sont réalisés sur la traduction ou l'interprétation du langage des signes ?**

Cette question devrait explorer les diverses recherches et développements effectués dans le domaine de la traduction et de l'interprétation du langage des signes, y compris les technologies émergentes et les avancées récentes.

— **Quels types de travaux sont réalisés sur le transfer learning ?**

Il serait utile de généraliser cette question pour inclure non seulement les travaux spécifiques au langage des signes mais aussi les applications plus larges du transfer learning, fournissant un contexte pour comprendre son utilisation dans des domaines variés.

- **Comment le transfer learning est-il appliqué dans le contexte de la détection et de la traduction du langage des signes ?**

Cette question vise à explorer les méthodes spécifiques et les approches utilisées pour appliquer le transfer learning dans la détection et la traduction du langage des signes, mettant en lumière les architectures de modèles et les stratégies d'entraînement.

- **Quels sont les défis de la traduction du langage des signes et quelles solutions le transfer learning offre-t-il ?**

En plus de décrire les défis, cette question devrait également mettre en évidence comment le transfer learning peut adresser ou atténuer ces défis, offrant ainsi des solutions potentielles ou des améliorations.

- **Quels défis et limitations sont rapportés lors de l'application du transfer learning à la détection et à la traduction du langage des signes ?**

Cette question cherche à identifier les obstacles techniques, les limites des données et les contraintes méthodologiques rencontrées lors de l'utilisation du transfert learning dans ce domaine spécifique.

1.2.2 Critères de recherche

Critères PICO :

Population	Études centrées sur les utilisateurs de la langue des signes et les technologies conçues pour la détection ou la traduction de la langue des signes. Article datant de 2014 au minimum. Etudes décrivant les applications du transfer learning.
Intervention	L'application des techniques d'apprentissage par transfert dans les tâches de détection et de traduction de la langue des signes.
Comparison	Comparaisons, lorsque disponibles, entre les approches d'apprentissage par transfert et les méthodes traditionnelles d'apprentissage automatique sans apprentissage par transfert.
Outcome	L'efficacité de l'apprentissage par transfert pour améliorer la détection ou la traduction de la langue des signes, les défis rencontrés et les lacunes dans la recherche actuelle.

TABLE 1.1 – Résumé des critères d'étude pour la détection et la traduction de la langue des signes.

La Table 1.1 présente les critères principaux (PICO) utilisés pour structurer notre recherche sur l'application du transfer learning à la reconnaissance et traduction du langage des signes. La section **Population** décrit les utilisateurs et les technologies concernées. La section **Intervention** précise l'application des techniques d'apprentissage par transfert dans ce contexte. La section **Comparison** évoque les comparaisons faites entre les approches d'apprentissage par transfert et les méthodes traditionnelles.

Enfin, la section **Outcome** résume les résultats attendus, les défis identifiés et les lacunes actuelles dans la recherche.

1.2.3 Termes clés et requêtes

Termes clés :

- "Transfer learning" / "knowledge transfer" / "pre-trained models"
- "Sign language recognition" / "Sign language translation"
- "from sign to text"
- "Sign language"
- "Machine learning or deep learning in sign language"
- "CNN" / "RNN" / "Transformers"

Les requêtes :

Requête 1 : Apprentissage par transfert et détection du langage des signes

```
("transfer learning" OR "knowledge transfer") AND  
("sign language recognition" OR "sign language detection") AND  
("deep learning" OR "machine learning")
```

Requête 2 : Modèles utilisés dans le transfer learning pour le langage des signes

```
("transfer learning" OR "fine-tuning" OR "pre-trained models")  
AND ("convolutional neural networks" OR "CNN" OR "recurrent neural networks"  
OR "RNN" OR "transformers")  
AND ("sign language translation" OR "sign language recognition")
```

Requête 3 : Articles qui se concentrent sur la reconnaissance de signe à texte

```
("From sign language gestures to text conversion")  
OR "Sign Language from sign to text")
```

1.2.4 Observations sur les articles obtenues

Dans cette partie nous allons observer différentes caractéristiques des différents articles pré-sélectionnés, qui nous permettront de diriger la suite de notre travail en déterminer les différents axes que nous aborderons.




FIGURE 1.1 – Tendence de publication au cours des 10 dernières années

La Figure 1.1 présente un graphique qui illustre les tendances de publication sur une période allant de 2014 à 2024. Il montre le nombre de publications par an dans le domaine de recherche du transfer learning et de la reconnaissance/traduction du langage des signes. À partir de 2019, le graphique indique une tendance à la hausse du nombre de publications, atteignant un pic en 2022. Après cette période, on observe une baisse des publications ces deux dernières années. La tendance générale suggère un accroissement de l'intérêt et des travaux de recherche. Cela pourrait indiquer un changement dans les priorités de recherche, l'émergence de nouvelles technologies, ou un changement d'intérêt vers d'autres domaines connexes après cette période.




FIGURE 1.2 – Fréquence des mots clés dans les différents titres et abstractes des articles

La Figure 1.2 présente un graphique qui illustre l'analyse de la fréquence des mots-clés dans les titres et les résumés dans la pré-sélection d'articles réalisés. On observe que le terme "sign language" apparaît avec la plus haute fréquence, suivi de près par "recognition". Les mots-clés "transfer learning" et "translation" montrent une occurrence modérée. En revanche, "deep learning" présentent les fréquences les plus basses parmi les termes analysés. Ce graphique indique les tendances dans les domaines de recherche associés et peut suggérer une concentration plus forte sur les études liées au langage des signes et à sa reconnaissance par rapport aux autres sujets listés. Cela représente bien la réalité car l'étude de la reconnaissance et de la traduction du langage des signes est un sujet de recherche qui est présent depuis de nombreuses années, le transfer learning est quand à lui assez récent, son application au domaine du traitement des langues des signes l'est encore plus.

1.2.5 Screening

Dans cette section, nous détaillons les différentes étapes qui ont permis de réduire le nombre d'articles à consulter, en précisant le nombre d'articles conservés et rejetés à chaque étape. Le nombre total d'articles avant le screening était de 150.

Première étape : Application des critères PICO Les critères PICO (Population, Intervention, Comparison, Outcome) ont été appliqués pour filtrer les articles. Tous les articles datant d'avant 2014, ainsi que ceux qui ne se concentraient pas sur la reconnaissance ou la traduction du langage des signes ou sur les diverses applications du transfert d'apprentissage, ont été exclus. Cette étape a permis de retenir 91 articles et de rejeter 59 articles.

Deuxième étape : Lecture des titres et des résumés Les titres et les résumés des articles restants ont été examinés pour vérifier leur pertinence par rapport au sujet traité. À l'issue de cette étape, 24 articles ont été retenus et 67 articles ont été rejetés.

Troisième étape : Lecture du plan détaillé et du contenu des articles Pour les articles restant, nous avons procédé à la lecture du plan détaillé, de certaines sections spécifiques ou de l'intégralité de l'article. Cette étape a permis de retenir 11 articles et d'en rejeter 13.

Quatrième étape : Recherche complémentaire Une recherche complémentaire a été effectuée pour identifier d'autres articles pertinents. Cette étape a permis d'ajouter 2 articles supplémentaires à notre sélection finale.

En résumé, le processus de screening a réduit le nombre d'articles de 150 à un total de 13 articles retenus pour une analyse approfondie.

1.3 Objectif du mémoire

L'objectif principal de ce mémoire est de déterminer dans quelle mesure le transfer learning peut être appliqué pour améliorer la reconnaissance du langage des signes. L'objectif est d'identifier les meilleures pratiques pour relever les défis liés à la diversité et à la complexité du langage des signes. De plus, ce travail se penchera sur des

problèmes techniques tels que le surapprentissage et la généralisation, et examinera comment le TL peut aider à rendre la technologie plus accessible et inclusive.

Dans ce mémoire, nous commencerons par examiner la méthodologie de recherche utilisée pour sélectionner les articles pertinents, ce qui nous permettra de situer l'état actuel de la recherche dans ce domaine. Le chapitre II passera en revue les différents travaux réalisés sur la reconnaissance du langage des signes. Le chapitre III présentera le transfert learning (TL) et ses diverses applications. Dans le chapitre IV, nous nous concentrerons sur des études de cas où le TL est appliqué à la reconnaissance des signes alphabétiques dans deux langues différentes : la langue des signes arabe (ArSL) et la langue des signes américaine (ASL). Le chapitre V explorera les perspectives actuelles et futures, y compris un exemple de modèle en zéro-shot. Le chapitre VI sera consacré à notre propre expérimentation, où nous construirons un dataset de l'alphabet LSF et entraînerons trois modèles, dont deux utilisant le TL. Enfin, nous conclurons nos travaux dans le chapitre VII.

Chapitre 2

Revue technologique portée sur la reconnaissance du langage des signes

2.1 Domaines d'application et tâches liées à la langue des signes

Cette partie abordera les diverses applications, les domaines d'études et tâches associés portés sur le sujet de la langue des signes.




FIGURE 2.1 – Représentation des différentes tâches réalisables sur le langage des signes

La reconnaissance de la langue des signes (LS) est un domaine qui exploite les progrès technologiques réalisés en machine learning pour améliorer la communication entre les personnes sourdes et entendantes. La revue de Marina Perea-Trigo et al. [6] couvre les différents cas d'utilisation et méthodes récentes dans la reconnaissance, la traduction et la production de la LS. On peut observer les divers domaines de recherches sur la Figure 2.1

Les tâches de reconnaissance de la LS peuvent être subdivisées en reconnaissance isolée, ISLC (pour "Isolated Sign Language Recognition") ou continue, CSLC (pour "Continuous Sign Language Recognition"). La reconnaissance isolée partage de nombreuses caractéristiques avec la reconnaissance d'action, où des techniques comme les

réseaux de neurones convolutifs (CNN) sont utilisées pour l'extraction de caractéristiques et la classification. La reconnaissance continue, en revanche, s'attache à la séquence des gestes effectués dans un flux continu de signes.

Pour la traduction de la LS, l'objectif final est de générer une phrase cohérente et significative dans la langue écrite à partir des signes. Cette tâche se heurte à certain défis, notamment au fait que les langues des signes n'ont pas de correspondance mot-à-mot avec les langues parlées/écrites, rendant la cartographie directe difficile. Des approches récentes se concentrent sur la reconnaissance de séquences de glosses formant la reconnaissance continue de la LS, qui ne fournit pas d'interprétation signifiante de ce qu'un signeur dit réellement, car les langues des signes ne partagent pas les propriétés grammaticales et linguistiques des langues parlées/écrites.



FIGURE 2.2 – Représentation des tâches de reconnaissance et traduction de signe pour la langue des signes espagnoles [6]

On peut observer grâce à la Figure 2.2 une tâche de CSLR et SLT (Sign language translation), dans un premier temps on a une tâche qui va permettre d'isoler et de reconnaître chaque signe présent dans la vidéo, à chaque signe est associé un label, la succession individuelle de ces signes et donc des mots associés à ces signes ne donnent pas vraiment de sens, c'est là que la traduction intervient, la traduction permet de donner un sens à l'ensemble des mots trouvés afin de former une phrase avec du sens.

[7] En ce qui concerne la production de la LS, elle implique la génération automatique de traductions en langue des signes à partir de textes ou de discours, connue sous le nom de production de la langue des signes. Cette recherche vise à synthétiser des vidéos à partir de chaque glose ou, alternativement, à générer des avatars pour signer la LS correspondante. Des projets comme HandTalk utilisent des avatars pour interpréter la LS en utilisant un interpréteur artificiel.

Ces avancées montrent l'importance de développer des systèmes capables de reconnaître, traduire et produire la langue des signes, afin de faciliter la communication entre la communauté sourde et le reste de la population, en s'appuyant sur les technologies de l'information et de la communication modernes.

2.2 Les avancées technologiques

Depuis de nombreuses années maintenant de nombreuses avancées technologiques ont vu le jour concernant les tâches réalisables autour du langage des signes. Des architectures et des modèles ont vu le jour. Nous allons tâcher de voir les technologies principales qui peuvent être utilisées dans les tâches SLR.

[3] Pour les tâches de reconnaissance et de traduction du langage des signes, plusieurs techniques et technologies sont utilisées pour capturer et analyser les données nécessaires. Ces méthodes varient selon les aspects des signes à détecter et la complexité de l'information à traiter.




FIGURE 2.3 – Représentation des techniques les plus utilisées pour traiter et récolter les signes sur des signeurs [3]

La Figure 2.3 illustre les techniques les plus couramment mises en place, soit RGB, Depth map, User index, Skeleton.

2.2.1 Les réseaux CNN

Dans l'article d'Adaloglou et al. [5], les auteurs expliquent comment ils utilisent les réseaux de neurones convolutifs (CNN) pour reconnaître les gestes et les séquences de mouvements dans les vidéos. Ils discutent de l'utilisation de CNN en 2D pour analyser chaque image individuellement, et de CNN en 3D pour mieux saisir les mouvements au fil du temps, car ces derniers traitent plusieurs images à la fois.

2DCNN (2-Dimensional Convolutional Neural Networks) Les 2DCNN sont une forme spécifique de CNN, conçus pour traiter des données en deux dimensions, comme les images. Dans ces réseaux, les filtres de convolution se déplacent dans deux directions (hauteur et largeur) pour capturer les caractéristiques spatiales de l'image. Ces réseaux sont idéaux pour des tâches telles que la reconnaissance faciale, la classification d'images, etc.

3DCNN (3-Dimensional Convolutional Neural Networks) Les 3DCNN étendent le concept des 2DCNN aux données tridimensionnelles. Ils sont particulièrement utiles pour analyser des vidéos ou des images médicales volumétriques, où il est important de capter les informations spatiales et temporelles. Dans un 3DCNN, les filtres de convolution se déplacent dans trois dimensions (hauteur, largeur, et profondeur/temporalité), ce qui permet de traiter l'évolution des caractéristiques au fil du temps dans le cas des

vidéos ou de capter la profondeur dans des images 3D.

Ils introduisent aussi une méthode innovante qui utilise plusieurs flux de données en même temps, comme des images de la main ou du visage du signeur, pour capturer plus de détails sur les gestes. Cette approche est combinée avec des réseaux de neurones LSTM (Long Short-Term Memory), qui aident à comprendre la séquence des gestes sur une période plus longue.

Toutefois, les auteurs notent des limites à ces techniques, comme le besoin de grandes quantités de données annotées pour l'entraînement et la difficulté de capturer les longues dépendances temporelles sans utiliser des LSTM ou des méthodes d'entraînement spéciales.

Ils mentionnent aussi des innovations comme l'utilisation de CNN temporels 1D pour améliorer la transition entre la capture des caractéristiques par les CNN et leur traitement par les LSTM, dans le but de rendre la reconnaissance des gestes plus précise et efficace malgré les défis.

2.2.2 Les réseaux RNN et Transformers

L'article de Camgoz et al. [4] introduit une méthode novatrice pour la reconnaissance et la traduction du langage des signes. Leur architecture, nommée "Sign Language Transformers", combine les réseaux de neurones récurrents (RNN) et les Transformers pour traiter les vidéos de signes de manière intégrée, sans segmentation préalable. Habituellement, pour traduire un langage des signes, les systèmes doivent identifier et isoler des segments individuels (des frames) qui représentent des unités de signification (comme des mots ou des phrases) avant de les traduire. Cette étape de segmentation est complexe et peut introduire des erreurs si les segments ne sont pas correctement identifiés, de plus on perd en partie le sens de la phrase car on ignore les transitions entre les frames (regards, mouvements de mains, du corps...).

L'objectif de leur étude était de développer un système qui peut simultanément reconnaître et traduire le langage des signes en texte parlé. Le système utilise des Transformers, qui sont des modèles d'apprentissage profond efficaces pour traiter les séquences temporelles et les dépendances complexes entre les données séquentielles. Ces modèles améliorent la compréhension et la génération de texte grâce à leurs mécanismes d'attention, qui focalisent sur différentes parties de la séquence de signes. Leur système leur permet d'analyser l'ensemble de la vidéo en continu, le modèle comprend le contexte global et les nuances de la langue des signes, permettant une traduction plus nuancée et précise.

Les tests ont montré que les "Sign Language Transformers" surpassent les modèles antérieurs, doublant presque les performances de traduction par rapport aux méthodes traditionnelles. Ces résultats confirment la puissance de l'apprentissage simultanée pour améliorer à la fois la reconnaissance et la traduction du langage des signes.

L'approche est innovante car elle utilise des Transformers pour la traduction directe du langage des signes sans segmentation temporelle, une première dans le domaine.

Cependant, l'étude admet certaines limitations, telles que la difficulté à traduire des locations ou des nombres sans contexte grammatical clair, et le défi de généraliser les résultats au-delà des jeux de données spécifiques utilisés pour l'entraînement.

2.3 Critique et perspectives : analyse critique des modèles actuels

Les modèles actuels de reconnaissance du langage des signes sont confrontés à des défis majeurs. Un obstacle significatif est le besoin de grandes quantités de données annotées, qui sont essentielles pour entraîner des modèles précis. Cependant, l'annotation est souvent coûteuse et prend du temps, limitant la quantité de données disponibles pour l'entraînement.

Un autre problème est que beaucoup de ces modèles se concentrent principalement sur les gestes des mains et tendent à négliger les expressions faciales et les mouvements du corps, qui sont pourtant des composants critiques de la communication en langage des signes. Cette omission peut réduire la capacité du modèle à interpréter correctement le langage des signes, car les gestes non manuels fournissent souvent des contextes émotionnels et grammaticaux importants.

En outre, les modèles peuvent avoir du mal à se généraliser au-delà des données spécifiques sur lesquelles ils ont été entraînés. Cela signifie qu'ils peuvent ne pas bien fonctionner avec de nouvelles données ou dans de nouvelles situations, limitant leur applicabilité. Les biais inhérents dans les données d'entraînement peuvent également être transférés dans les modèles, ce qui peut entraîner des performances inégales et des préjugés dans la reconnaissance des signes.

Pour avancer, il est nécessaire de développer des méthodes qui peuvent réduire la dépendance aux vastes ensembles de données annotées, incorporer efficacement les gestes non manuels et améliorer la capacité de généralisation des modèles. Identifier et aborder ces lacunes est essentiel pour créer des systèmes de reconnaissance des signes plus robustes et inclusifs.

Chapitre 3

Le Transfer Learning : Théorie et application

3.1 Fondements du transfer learning

L'article de Weiss et al. [1] se présente comme un examen approfondi du TL définissant formellement ce concept, exposant les solutions actuelles, et évaluant ses applications pratiques. Le transfer learning est une méthode qui permet à un modèle d'utiliser les connaissances acquises sur une tâche pour améliorer les performances sur une autre tâche similaire mais différente. Cette approche est particulièrement utile lorsque les données disponibles pour la nouvelle tâche sont insuffisantes pour entraîner un modèle. En exploitant les connaissances d'un domaine source pour améliorer l'apprentissage dans un domaine cible, le TL surmonte l'un des défis majeurs de l'apprentissage automatique traditionnel lié à la nécessité de grandes quantités de données d'entraînement.

Le Transfer learning est motivé par des scénarios où il est coûteux ou difficile de recueillir des données d'entraînement qui correspondent exactement à l'espace des caractéristiques et aux caractéristiques de distribution des données de test.

3.1.1 Les différents types de Transfer Learning

L'article de Weiss et al. [1] distingue deux types principaux de transfert selon la relation entre les espaces de caractéristiques des domaines source et cible :

- Transfer Learning Homogène : Le transfer learning homogène se produit lorsque les domaines source et cible utilisent les mêmes types de données et caractéristiques. Par exemple, si vous avez un modèle qui prédit les prix des maisons à Paris et que vous souhaitez l'utiliser pour prédire les prix à Lyon (on utilise les mêmes caractéristiques, la superficie, le quartier...)

- Transfer Learning Hétérogène : Au contraire le transfer learning hétérogène est nécessaire lorsque les domaines source et cible utilisent différents types de données. Un parfait exemple de ce transfert est illustré dans l'article Laith Alzubaidi et al. [15] qui pré-entraîne plusieurs modèles avec un dataset source important de photos d'animaux dans le but de réaliser une tâche de reconnaissance d'image médicale, plus précisément des photos d'ulcère sur des pieds de diabétiques, plusieurs scénarios ont été réalisés dans

cette étude dont celui de choisir un dataset source qui n'avait rien avoir avec le dataset et la tâche cible. Les résultats étaient très convaincants car les différents scores de précision pour les différents scénarios dont celui évoqué étaient supérieur à 80% dans les moins bon cas.

Ces deux catégories peuvent également être influencées par des différences dans les distributions marginales ou conditionnelles des domaines, nécessitant des adaptations spécifiques.

3.1.2 Les méthodes et stratégies pour aborder le Transfer Learning

L'article de Weiss et al. [1] passe en revue diverses méthodes et stratégies pour aborder le TL, y compris :

1. Techniques basées sur les caractéristiques (Feature-based Transfer) : Ces techniques s'efforcent de trouver un espace de caractéristiques commun entre le domaine source et le domaine cible, permettant au modèle d'appliquer les connaissances acquises sur les données source pour mieux interpréter les données cible.
2. Techniques basées sur les paramètres (Parameter-based Transfer) : Cette catégorie inclut les méthodes qui transfèrent certains paramètres ou poids d'un modèle pré-entraîné dans le domaine source vers un modèle dans le domaine cible, ajustant finement le modèle sur les données cibles.
3. Techniques basées sur les relations (Relational-based Transfer) : Ces approches cherchent à transférer des connaissances à un niveau plus abstrait, en exploitant les relations ou les structures inhérentes aux données, indépendamment des caractéristiques ou des paramètres spécifiques des modèles.

3.1.3 Défis liés à l'application du Transfer Learning

L'application du Transfer Learning (TL) présente plusieurs défis notables :

- **Spécificité de l'application** : Certains algorithmes de TL sont conçus pour des applications très spécifiques, limitant leur applicabilité à d'autres domaines ou problèmes.
- **Transfert négatif** : Le transfert négatif se produit lorsque le transfert de connaissances entre le domaine source et le domaine cible dégrade les performances du modèle sur le domaine cible.
- **Manque de données étiquetées** : La plupart des approches de TL nécessitent des données étiquetées dans le domaine cible pour l'ajustement fin ou l'adaptation du modèle. Cependant, dans de nombreux cas pratiques, seules des données non étiquetées sont disponibles, posant un défi supplémentaire pour l'application efficace de ces techniques.

Bien que le TL représente une avancée prometteuse, offrant des solutions innovantes pour surmonter les limitations des approches traditionnelles d'apprentissage automatique, la recherche continue est essentielle pour surmonter ses défis spécifiques. En outre, il est crucial d'étendre son applicabilité à une gamme plus large de domaines et

de tâches.

3.2 Exemples d'application et élargissement : la polyvalence et l'applicabilité du transfer learning

L'article de Weiss et al. [1] met en lumière la diversité et la polyvalence du transfer learning à travers une variété d'applications dans différents domaines, soulignant son potentiel considérable pour résoudre des problèmes complexes avec des données limitées ou spécifiques à un domaine.

Applications en Traitement du Langage Naturel (NLP) Dans le domaine du traitement du langage naturel (NLP), l'utilisation de modèles pré-entraînés pour des tâches de classification de texte et d'analyse de sentiment démontre une capacité d'adaptation à des contextes linguistiques variés. Ces applications montrent comment le transfer learning améliore la compréhension et le traitement des langues naturelles en utilisant des connaissances acquises à partir de données dans des domaines ou des langues similaires.

Classification d'Images et de Vidéos Le transfer learning a également prouvé son efficacité dans la classification d'images et de concepts vidéo. Des modèles pré-entraînés (comme ceux d'ImageNet) sur de vastes ensembles de données peuvent être affinés pour reconnaître de nouveaux objets ou catégories avec une précision remarquable.

Applications Diverses D'autres applications notables incluent :

- la classification de la localisation WiFi,
- la classification de la fatigue musculaire,
- la classification de l'efficacité des médicaments,
- la classification de l'activité humaine,
- la classification des défauts logiciels,
- la classification des arythmies cardiaques.

Ces exemples illustrent la flexibilité du transfer learning à s'adapter et à fournir des solutions dans un large éventail de domaines.

Applications Innovantes Parmi les applications innovantes, on trouve :

- l'utilisation du transfer learning pour la classification des particules d'aérosols atmosphériques pour améliorer les modèles climatiques globaux,
- la cartographie de la pauvreté dans les pays en développement en prédisant l'intensité de la lumière nocturne à partir des données d'images satellites,
- l'amélioration de la prédiction des maladies en utilisant des données abstraites de domaines sources pour modéliser différents types de données d'expression génique.

Ces exemples soulignent non seulement la polyvalence du transfer learning mais aussi son potentiel à contribuer significativement à des avancées dans des domaines variés, en offrant des solutions innovantes pour des problèmes complexes. La capacité du transfer learning à exploiter les connaissances acquises dans un domaine pour améliorer les performances dans un autre ouvre de nouvelles voies pour la recherche et l'application pratique dans de nombreux champs disciplinaires.

Chapitre 4

Application du transfer learning à la reconnaissance du langage des signes

Dans ce chapitre nous allons désormais voir l'application de cette technologie au niveau de la reconnaissance des signes de l'alphabet Arabe et d'une sélection de mots signés en indien.

4.1 Études de cas : Analyse des études existantes qui ont employé l'apprentissage par transfert dans ce domaine

Quelques études ont été réalisées sur l'application du TL [8, 9, 10] sur des alphabets et des mots en plusieurs langues des signes, Américain, Arabe, Indien. Ces études montrent l'utilisation du TL appliqué à la reconnaissance des signes avec des datasets plus ou moins importants, mais assez pauvres dans le but de faire valoir l'utilisation du TL, tout en nous permettant de souligner ces limites. Nous allons entrer dans le détail de deux de ces études.

4.1.1 Application du Transfer Learning à la reconnaissance de l'alphabet de la langue des signes Arabe

Dans l'étude réalisée par Mohammed Zakariah et ses collaborateurs, [10] l'application de l'apprentissage par transfert à la reconnaissance du langage des signes de l'alphabet arabe est explorée à travers une méthodologie détaillée et structurée. Cette section résume la méthodologie employée et les résultats clés obtenus.

Dans l'étude réalisée par Mohammed Zakariah et ses collaborateurs [10], l'application de l'apprentissage par transfert à la reconnaissance de l'alphabet de la langue des signes arabes est explorée à travers une méthodologie détaillée et structurée. Cette section résume la méthodologie employée et les résultats clés obtenus.

Méthodologie Employée :

1. **Prétraitement des Données :** L'étape initiale a consisté à préparer les données pour l'entraînement. Cela inclut le nettoyage, la normalisation et l'application

de techniques d'augmentation des données pour enrichir l'ensemble d'apprentissage et pour que la solution puisse s'adapter à différents environnements. Le dataset original contenait 54 049 images, avec environ 1 500 images par classe, pour un total de 32 lettres représentées (donc 32 classes). Pour chaque classe, 1 000 images ont été sélectionnées, totalisant 32 000 images. Des techniques d'augmentation de données ont ensuite été appliquées, générant ainsi 5 000 images par classe, soit un total de 160 000 images. Le but de ce prétraitement est d'éviter le surapprentissage et le sous-apprentissage.

2. **Utilisation de l'Apprentissage par Transfert** : La stratégie principale a été l'apprentissage par transfert, où plusieurs architectures de réseaux de neurones convolutifs (CNN) pré-entraînées sur le dataset ImageNet ont été adaptées et personnalisées pour la tâche spécifique de reconnaissance du langage des signes arabe.
3. **Choix des Modèles** : Parmi divers modèles pré-entraînés, l'EfficientNetB4 s'est distingué par ses performances supérieures, démontrant l'efficacité de sélectionner une architecture optimale pour la tâche en question.

Résultats Principaux :

- **Génération d'Images Augmentées** : Un total significatif de 160 000 images augmentées a été généré à partir de l'ensemble original, contribuant à la robustesse et à la généralisabilité du modèle.
- **Performance du Modèle** : Le modèle a démontré une haute précision et efficacité, validant l'approche d'apprentissage par transfert pour la reconnaissance des gestes de la main en langue des signes arabe sur un ensemble de données inédit.
- **Amélioration par Rapport aux Travaux antérieurs** : Les techniques de prétraitement et les ajustements d'architecture ont joué un rôle crucial, aboutissant à des résultats qui surpassent ceux des études précédentes, offrant ainsi une solution plus généralisée et efficace.

Cette méthodologie met en lumière l'importance de l'apprentissage par transfert et de l'optimisation des architectures de CNN dans l'avancement de la reconnaissance précise du langage des signes. Les innovations dans le traitement et l'augmentation des données ainsi que le choix judicieux des modèles CNN contribuent à des avancées significatives dans ce domaine.

4.1.2 Reconnaissance d'une sélection de mots signés en indien en temps réel

L'article de Lipika Goel et al. [8] explore l'application du transfer learning pour la reconnaissance du langage des signes en temps réel. Cette approche se distingue par son efficacité dans la réduction du temps de formation des modèles, l'atteinte d'une

haute précision et la nécessité de moins d'images pour l'entraînement. La méthodologie proposée utilise le TL, qui implique l'ajustement des paramètres de la dernière couche d'un modèle pré-entraîné. Cela réduit significativement le temps d'entraînement et requiert un petit ensemble de données de moins de 20 images par geste.

Le travail s'appuie sur un dataset personnalisé généré à l'aide d'une webcam et d'une interface permettant de labelliser les images. L'utilisation de l'API de détection d'objets TensorFlow a été employée pour télécharger un modèle pré-entraîné nommé "SSD MobinetNet V2". Grâce à cette approche, les auteurs ont pu obtenir de très bons résultats en termes de précision, avec une précision moyenne supérieure à 80% pour les différents signes abordés dans l'article. Ils soulignent que de telles précisions avec un petit dataset ont été principalement possibles grâce à l'application du Transfer Learning.

L'article mentionne également l'efficacité de l'apprentissage par transfert dans d'autres cas d'utilisation de computer vision, tels que la détection de masques faciaux et d'autres détections de langage des signes, soulignant la polyvalence et l'efficacité de cette méthode. Il est indiqué que le modèle de reconnaissance peut être étendu pour détecter un nombre quelconque de signes sans se limiter aux quelques classes sélectionnées pour l'expérimentation, et que pour atteindre de plus grandes précisions, il est possible d'augmenter la taille du dataset ainsi que le nombre d'étapes d'entraînement.

En conclusion, l'article présente une solution efficace pour la mise en œuvre de la reconnaissance du langage des signes en temps réel à l'aide de l'apprentissage par transfert, offrant une voie prometteuse pour l'amélioration de la communication sans barrières pour les personnes sourdes et muettes.

4.2 Performances et limitations de ces cas d'études

L'examen de deux études sur l'utilisation de l'apprentissage par transfert dans la reconnaissance de l'alphabet arabe et de certains signes indien révèle des avancées prometteuses en termes de performances et d'efficacité, mettant en lumière le potentiel de cette technologie.

Points Communs entre les Études

- **Performances Élevées** : Les analyses montrent que le TL peut atteindre une précision élevée dans la reconnaissance du langage des signes, avec des précisions moyennes dépassant les 80% et allant jusqu'à 98% pour l'entraînement et 95% pour les tests.
- **Avantages Notables** : L'efficacité de l'apprentissage par transfert se manifeste par une réduction considérable du temps et des ressources nécessaires à l'entraînement des modèles. Cette méthode présente également une grande scalabilité, adaptable à divers langues des signes.

Distinctions Clés

- **Diversité des Données** : Tandis que l'une des études s'appuie sur un ensemble de données restreint [8], l'autre tire parti d'un volume de données plus conséquent

et diversifié [10], illustrant l'importance d'une base de données riche pour la formation des modèles.

- **Défis Techniques** : Les obstacles rencontrés varient, allant des problèmes liés à l'étiquetage des données et aux conditions expérimentales, à la nécessité de disposer de données de haute qualité pour assurer la robustesse des modèles.

Contributions Significatives

- **Innovation en Temps Réel** : L'une des études démontre l'utilité de l'apprentissage par transfert pour la reconnaissance rapide et efficace du langage des signes, proposant une méthode évolutive.
- **Avancées Techniques** : L'autre étude met en avant l'impact des architectures CNN avancées et l'importance de l'augmentation des données, offrant une amélioration significative des performances par rapport aux recherches précédentes.

Limitations

Les deux études sont sujettes au surapprentissage, dû à une limitation des données. Dans l'article [10], en étudiant les courbes de pertes d'entraînement et de validation fournies par les auteurs, on observe que la courbe de perte de validation coupe et passe au-dessus de celle d'entraînement après peu d'époques (moins de 10), ce qui pourrait être un signe de surapprentissage. Cependant, les auteurs considèrent que le modèle s'est juste bien ajusté aux données.

Dans l'étude [8], les auteurs ne parlent pas du tout de surapprentissage. Or, avec 16 images par classe et en utilisant un réseau de neurones, on peut facilement se douter qu'il y a un grand risque de surapprentissage, les données étant extrêmement limitées.

Conclusions et voies futures

L'apprentissage par transfert se révèle être un levier puissant pour la reconnaissance du langage des signes, proposant des avancées significatives tout en identifiant des pistes d'amélioration.

L'apprentissage par TL nécessite en effet moins de données. En réussissant à transférer l'apprentissage d'un modèle pré-entraîné sur un dataset riche dans le but de réaliser une tâche similaire à la tâche cible, on arrive à réduire les besoins en ressources et donc à pallier un problème important du ML. Cependant, ne pouvant entraîner notre modèle que sur un nombre de données limitées, on est enclin au surapprentissage.

En résumé, l'apprentissage par transfert présente un potentiel considérable pour la reconnaissance du langage des signes, promettant des avancées significatives. Cependant, des défis considérables liés à la qualité des données, à l'adaptation du modèle et au surapprentissage sont à prendre en compte.

Chapitre 5

Perspectives actuelles et futures

5.1 Innovations récentes et études de cas

Examen des avancées technologiques et de leur impact : Zéro-Shot Learning

L'article de Yunus Can Bilge et al. [12] aborde le problème de l'apprentissage en zéro-shot pour la reconnaissance des signes. Le but principal est de développer un modèle capable de reconnaître des signes non vus lors de la phase d'entraînement, en utilisant des informations auxiliaires telles que des descriptions textuelles et des attributs prédéfinis.

Méthodologies employées

Le document décrit une approche où deux sources d'information sont utilisées : le domaine visuel, comprenant des vidéos de signes, et un domaine auxiliaire, incluant des descriptions de classes basées sur des descriptions textuelles ou des attributs. Ces descriptions couvrent divers aspects comme la forme de la main, l'orientation de la paume, les mouvements des mains, et leur localisation par rapport au corps, ainsi que des indices non manuels tels que les expressions faciales et les postures du corps. Une attention particulière est portée aux descriptions détaillées des signes pour assurer une compréhension claire des gestes.

Les datasets élaborés dans cette étude utilisent des vidéos de signes collectées à partir de sources publiques, enrichies par des descriptions textuelles et des attributs issus de dictionnaires spécialisés en langue des signes. Ces enrichissements servent de représentations sémantiques, essentielles pour faciliter le transfert de connaissances entre les classes de signes déjà connues et celles non vues lors de la formation des modèles.

ASL-Text

Ce dataset est développé à partir de l'ASLLVD, qui est l'un des ensembles de données les plus volumineux pour la reconnaissance isolée des signes. Les 250 classes de signes les plus couramment utilisées sont sélectionnées et enrichies avec des définitions textuelles provenant du Webster American Sign Language Dictionary. Les descriptions détaillées couvrent des aspects cruciaux tels que la forme de la main, l'orientation de la paume, les mouvements des mains et leur positionnement par rapport au corps,

fournissant ainsi une base riche pour le traitement sémantique des signes.

MS-ZSSLR-W et MS-ZSSLR-C

Ces ensembles de données sont dérivés du MS-ASL, adaptés pour inclure des descriptions textuelles et des attributs, augmentant ainsi leur utilité pour les tests en conditions réelles et contrôlées. Le MS-ZSSLR-W (Wild) contient des vidéos enregistrées dans des environnements non contrôlés, intégrant une grande diversité et présentant des défis supplémentaires liés aux variations naturelles dans l'exécution des signes. À l'inverse, le MS-ZSSLR-C (Clean) se compose de vidéos filtrées pour exclure les dialectes et inclure uniquement les signes conformes aux définitions standardisées.

Modèles et résultats

Les auteurs introduisent un modèle innovant de classification en zéro-shot qui utilise les étiquettes enrichies pour l'apprentissage. Le modèle s'appuie sur une fonction de compatibilité qui évalue et associe chaque vidéo à une classe en fonction de la confiance que cette vidéo représente un signe particulier. Cette méthode permet de classer efficacement des signes jamais vus auparavant en s'appuyant uniquement sur des informations sémantiques extraites.

Cet article apporte une contribution significative à la reconnaissance des signes en zéro-shot en introduisant des méthodes robustes pour gérer les variations inhérentes aux signes de la langue des signes et en établissant des benchmarks détaillés pour la communauté scientifique. En développant des modèles qui peuvent interpréter des signes sans exemples visuels préalablement annotés, cette recherche ouvre des perspectives prometteuses pour l'accessibilité et l'interaction homme-machine, rendant les technologies d'assistance plus inclusives pour la communauté sourde et malentendante.

5.2 Potentiel d'amélioration et directions de recherche

Cette section explore les opportunités d'optimisation et les nouveaux champs de recherche émergents dans le domaine de la reconnaissance du langage des signes grâce à des approches innovantes en apprentissage machine.

Intégration des informations complémentaires :

La reconnaissance efficace du langage des signes ne se limite pas uniquement aux mouvements des mains. Les expressions faciales, les mouvements du corps, et les transitions entre les signes jouent un rôle crucial dans la transmission du sens. La recherche future pourrait se concentrer sur des modèles capables d'analyser ces aspects multimodaux pour une compréhension plus riche et nuancée des langues des signes.

Apport de l'apprentissage par transfert :

L'apprentissage par transfert a démontré son efficacité pour plusieurs alphabets et certains signes de différentes langues des signes avec des ensembles de données limités. Approfondir cette technique pourrait permettre d'adapter des modèles pré-entraînés à des langues des signes moins documentées, améliorant ainsi la performance sans nécessiter de vastes corpus de données.

Zéro-Shot Learning pour la reconnaissance de nouveaux signes :

Le zéro-shot learning, qui permet à un modèle de reconnaître des signes jamais vus durant l'entraînement, offre une perspective fascinante pour l'expansion des capacités des systèmes de reconnaissance du langage des signes. Cette approche pourrait révolutionner la manière dont les modèles apprennent et généralisent à partir de données limitées.

Impact d'une recherche approfondie sur la Langue des Signes Française (LSF) :

En se concentrant sur la LSF, langue pour laquelle les ressources sont encore insuffisantes, les recherches pourraient non seulement améliorer la technologie de reconnaissance pour cette langue spécifique mais aussi ouvrir des perspectives sur les adaptations nécessaires pour d'autres langues des signes régionales ou moins connues.

Ces directions proposent non seulement des améliorations techniques mais suggèrent aussi une évolution vers une compréhension et une intégration plus inclusives des besoins de la communauté sourde et malentendante. En poursuivant ces axes de recherche, il est possible de progresser vers une technologie plus accessible et efficace pour tous.

Chapitre 6

Expérimentation

L’objectif principal de cette expérimentation est de démontrer que le transfert d’apprentissage (transfer learning) constitue une solution efficace pour les tâches de reconnaissance des signes, particulièrement dans les contextes où les datasets sont limités, comme c’est le cas pour la Langue des Signes Française (LSF). Ici on se concentrera sur l’alphabet de la LSF. En développant notre propre dataset puis en utilisant des modèles pré-entraînés sur un dataset plus larges et plus diversifié, nous visons à construire des modèles performants sur notre dataset spécifiques à la LSF, malgré la quantité restreinte de données disponibles. Cette approche permet de tirer parti des connaissances acquises sur des tâches similaires et de les adapter efficacement à de nouvelles tâches, optimisant ainsi la précision et la robustesse des modèles de reconnaissance des signes.

6.1 Constitution du dataset

La constitution du dataset est une étape cruciale dans le développement de tout modèle de machine learning, en particulier pour la reconnaissance du langage des signes où la diversité et la qualité des données sont essentielles. Voici un aperçu des choix et méthodes employés pour cette étape.

6.1.1 Collection des Données

1. Sélection des Signeurs

- *Diversité des Signeurs* : Quatre signeurs différents (non malentendants et non habitués au langage des signes) ont été sélectionnés pour réaliser les signes. Cette diversité permet d’obtenir des variations naturelles dans les gestes, ce qui aide le modèle à généraliser mieux et à être moins sensible aux particularités individuelles des signeurs. La Table 6.1 présente les caractéristiques physiques des différents signeurs.

Signeur	Sexe	Âge	Taille
1	F	12	160 cm
2	M	55	170 cm
3	M	21	185 cm
4	F	49	159 cm

TABLE 6.1 – Caractéristiques des Signeurs

2. Quantité de Données

- *Nombre d'Images* : Pour chaque signe, environ 50 photos ont été prises par signeur, résultant en un total d'environ 200 images par signe/classe. Au total, le dataset contient 4200 images.

- *Nombre de Classes* : 21 lettres, seules les lettres dont les signes étaient statiques ont été sélectionnées, excluant ainsi 5 lettres (J, P, X, Y, Z) dont les signes sont dynamiques.

- *Balance des Classes* : Il est crucial de s'assurer que chaque classe (chaque signe) est représentée de manière équilibrée pour éviter les biais de classe. Un effort particulier a été fait pour maintenir un nombre équivalent de photos par signe. Chaque signe contient le même nombre de photos avec la même proportion pour chaque signeur.

- *Dimension des Images* : 3000x4000 pixels avant redimensionnement.

3. Conditions de Prise de Vue

- *Distance* : Les photos se situent entre 0.2 et 1 mètre.

- *Variabilité des Angles* : Les photos ont été prises sous différents angles (légères rotations de la main) et à différentes distances (rapprochements et éloignements de la caméra) pour simuler les conditions réelles d'utilisation et augmenter la diversité des données. Des rotations d'environ 15 à 30° ont été demandées aux signeurs durant la prise de photos.

- *Fond de l'Image* : Un même fond blanc a été utilisé pour l'arrière-plan.

- *Variation de Luminosité* : Certaines photos ont été prises avec une luminosité moins importante.




FIGURE 6.1 – Représentation de tous les signes pour les lettre sélectionnées

6.1.2 Prétraitement des Données

1. Redimensionnement des Images

- *Uniformisation des Dimensions* : Toutes les images ont été redimensionnées dans deux dimensions différentes : 64x64 pixels pour que les entraînements des différents modèles ne soient pas trop lourds, et 224x224 pixels, couramment utilisé dans les modèles de classification d'image et compatible avec les architectures pré-entraînées comme MobileNetV2. Ce format a été sélectionné uniquement pour MobileNetV2 car c'est un modèle destiné aux systèmes embarqués, qui a un coût d'entraînement moindre et peut encaisser ce format sans que cela soit trop coûteux durant l'entraînement.

- *Maintien des Proportions* : Le redimensionnement a été réalisé tout en maintenant les proportions pour éviter toute distorsion des signes.

Les dimensions utilisées dans cette expérimentation sont donc 224x224 pixels et 64x64 pixels avec un format de photos JPG.

2. Conversion en Niveaux de Gris

- *Réduction de la Complexité* : La conversion des images en niveaux de gris a été envisagée pour réduire la complexité du modèle en supprimant les informations de couleur, qui ne sont pas essentielles pour la reconnaissance des signes. Toutefois, cette étape a été réalisée uniquement pour l'un des entraînements du modèle de référence car les modèles pré-entraînés ne supportent que le format RGB.

3. Organisation des Données

- *Répertoires Structurés* : Les images ont été organisées en répertoires structurés par classe (lettre de l'alphabet) et par signeur, facilitant ainsi leur utilisation avec des générateurs de données pour l'entraînement et la validation.

- *Répartition en Ensembles* : Le dataset a été divisé en trois ensembles distincts : entraînement (70%), validation (15%) et test (15%). Cette répartition permet d'entraîner le modèle sur un sous-ensemble des données, de valider ses performances en cours d'entraînement et d'évaluer ses performances finales sur des données totalement inédites. Notre structure lettre/signeur nous permet d'avoir une même proportion de signeurs dans la construction des datasets train, validation et test. La table 6.2 résume la répartition du dataset, soit le nombre de photos par section.

Dataset après redimensionnement et répartition

Classes	Train	Validation	Test	Total
21 lettres	2940 photos	588 photos	672 photos	4200 photos

TABLE 6.2 – Répartition du dataset après redimensionnement

Architecture du Dataset

```
dataset/
|-- train/
|   |-- A/
|   |-- B/
|   |-- ...
|-- validation/
|   |-- A/
|   |-- B/
|   |-- ...
|-- test/
|   |-- A/
|   |-- B/
|   |-- ...
```

6.2 Augmentation des données

L'augmentation des données est une technique cruciale pour améliorer la performance et la robustesse des modèles de deep learning, en particulier lorsqu'il s'agit de tâches de classification d'images telles que la reconnaissance du langage des signes. Dans cette partie de l'expérimentation, nous discuterons des différentes techniques d'augmentation des données et de leur impact sur la réduction des biais et l'amélioration de la généralisation du modèle.

6.2.1 Techniques d'Augmentation des Données

L'augmentation des données consiste à créer des versions modifiées des images originales dans le but de diversifier le dataset sans avoir à collecter de nouvelles données.

Cette technique est particulièrement utile lorsque la collecte de données est coûteuse ou difficile. Voici les techniques que nous avons utilisés :

Rotation

Tourner l'image autour de son centre de quelques degrés dans les deux sens, ici plus ou moins 20°. Le but est de simuler des variations naturelles dans l'orientation des signes. Cela aide le modèle à apprendre à reconnaître un signe indépendamment de son orientation.

Translation

Déplacer l'image horizontalement ou verticalement, jusqu'à 20% de la largeur de l'image. Le but est de simuler le déplacement de la main dans le cadre de la caméra. Cela permet au modèle de mieux généraliser aux variations de position des signes.

Zoom

Agrandir ou réduire l'image, jusqu'à 20% de zoom avant ou arrière. Le but est de simuler des variations dans la distance entre la main et la caméra. Cela aide le modèle à reconnaître les signes même si la main est plus proche ou plus éloignée de la caméra.

Flipping

Retourner l'image horizontalement. Le but est d'augmenter la diversité des images en créant des miroirs des signes. Cela est particulièrement utile si le dataset original manque de variations de côté.

Shearing

Appliquer une transformation affine pour incliner l'image le long de l'axe horizontal ou vertical. Le but est de simuler des déformations de la main ou des mouvements rapides, améliorant ainsi la robustesse du modèle face à de telles variations, 20% de cisaillement.

Brightness Adjustment

Modifier la luminosité de l'image. Le but est de simuler des conditions d'éclairage différentes. Cela aide le modèle à être invariant aux variations de lumière.

Normalization

Redimensionner les valeurs de pixel pour qu'elles se situent dans une plage spécifique (généralement entre 0 et 1). On divise donc les valeurs des pixels [0, 255] par 255. Le but est de standardiser les données pour améliorer la convergence du modèle lors de l'entraînement.

6.2.2 Rôle de l'augmentation des données

1. Réduction des biais

- *Diversité des Données* : En appliquant des transformations aléatoires, nous pouvons simuler une variété de conditions de prise de vue. Cela réduit les biais potentiels dus à des conditions spécifiques de collecte de données, comme l'éclairage ou l'orientation.

2. Amélioration de la généralisation

- *Robustesse aux variations* : En exposant le modèle à des versions transformées des images, il apprend à reconnaître les signes malgré les variations d'orientation, de position, de taille, et de luminosité. Cela améliore la capacité du modèle à généraliser à de nouvelles images non vues pendant l'entraînement.

- *Prévention du surapprentissage (Overfitting)* : L'augmentation des données augmente efficacement la taille du dataset, ce qui aide à éviter que le modèle ne mémorise simplement les exemples d'entraînement. Au lieu de cela, il apprend des caractéristiques plus générales des signes, réduisant ainsi le risque de surapprentissage.

3. Enrichissement du dataset

- *Synthèse de nouveaux exemples* : Chaque image originale peut générer plusieurs images augmentées, enrichissant ainsi le dataset sans avoir à collecter de nouvelles données. Cela est particulièrement utile dans les domaines où la collecte de données est difficile ou coûteuse.

- *Flexibilité et contrôle* : L'utilisation de bibliothèques comme `ImageDataGenerator` de la bibliothèque `tensorflow.keras.preprocessing.image` permet un contrôle précis sur les types et les degrés de transformation appliqués, permettant d'adapter l'augmentation des données aux besoins spécifiques de l'expérimentation.

Cela contribue à rendre le modèle plus apte à reconnaître les signes dans des conditions variées, augmentant ainsi son utilité et sa fiabilité dans des scénarios réels.

6.3 Sélection des modèles

6.3.1 Choix des modèles

CNN (modèle de référence) :

Justification : Les CNN sont particulièrement efficaces pour les tâches de classification d'images grâce à leur capacité à capturer les caractéristiques spatiales des données. Ils sont robustes pour des tâches de reconnaissance de motifs, comme la reconnaissance des signes de la main.

Structure : 4 blocs successifs de cette forme :

- **Couches Convolutionnelles** : Capturent les motifs locaux dans les images.
- **Batch Normalization** : Normalise les activations des couches pour stabiliser et accélérer l'entraînement.
- **MaxPooling** : Réduit la dimensionnalité des caractéristiques et contrôle le surapprentissage.
- **Dropout** : Préviend le surapprentissage en désactivant aléatoirement une fraction des unités pendant l'entraînement.

On a donc limité le nombre de couches convolutionnelles à 4 car aucune amélioration n'a été remarquée lors de l'ajout supplémentaire d'une couche ou d'un retrait.

VGG16 :

Justification : VGG16 est un modèle profond pré-entraîné sur ImageNet, qui a montré d'excellentes performances en classification d'images. Son architecture simple mais profonde permet de capturer des caractéristiques complexes.

- **Geler les couches :** Les couches convolutionnelles pré-entraînées sont gelées pour conserver les caractéristiques apprises sur ImageNet.
- **Adaptation :** Ajout de couches fully connected supplémentaires pour s'adapter à la tâche de classification des signes.

MobileNetV2 :

Justification : MobileNetV2 est conçu pour être léger et efficace, ce qui est avantageux pour les applications en temps réel sur des dispositifs avec des ressources limitées. Pré-entraîné sur ImageNet, il offre une bonne base pour le transfert d'apprentissage.

- **Geler les couches :** Similaire à VGG16, les couches convolutionnelles sont gelées pour conserver les caractéristiques apprises.
- **Adaptation :** Ajout de couches fully connected et de couches de normalisation pour améliorer la généralisation et s'adapter à notre tâche.

6.3.2 Justification des Choix des couches, des hyperparamètres

Convolutionnelles : Les multiples couches convolutionnelles permettent de capturer des caractéristiques de bas niveau (bords, textures) à des caractéristiques de haut niveau (formes, objets).

Fully Connected : Les couches fully connected en fin de réseau permettent de combiner les caractéristiques extraites pour effectuer la classification finale.

Fonctions d'Activation :

- **ReLU :** Utilisée pour éviter les problèmes de gradient nul et permettre une convergence rapide.
- **Softmax :** Utilisée en couche de sortie pour les tâches de classification multi-classes.

Régularisation :

- **Dropout :** Aide à prévenir le surapprentissage en introduisant du bruit dans le réseau pendant l'entraînement.
- **L2 Regularization :** Pénalise les poids élevés pour éviter le surapprentissage et améliorer la généralisation.

6.3.3 Apprentissage par transfert :

ImageNet : Un dataset contenant des millions d'images classifiées en milliers de catégories. Les modèles pré-entraînés sur ce dataset ont appris à extraire des caractéristiques générales qui peuvent être réutilisées pour d'autres tâches de classification

d'images.

VGG16 :

Comme décrit précédemment, lors du pré-entraînement, une instance du modèle VGG16 pré-entraîné sur ImageNet est chargée. On utilise les poids appris sur ImageNet pour initialiser le modèle. Des couches fully connected supplémentaires sont ensuite ajoutées pour que le modèle puisse s'adapter à notre tâche de classification des signes de l'alphabet de la LSF.

MobileNetV2 :

Les mêmes étapes que pour le modèle VGG16 sont réalisées.

6.4 Entraînement et validation des modèles

L'entraînement du modèle est une étape cruciale qui consiste à ajuster les poids du modèle pour minimiser la fonction de perte sur le dataset d'entraînement. Cette section décrit les choix et les techniques utilisés pour configurer et réaliser l'entraînement du modèle de reconnaissance des signes.

6.4.1 Configuration de l'Entraînement

1. Définition des Générateurs de Données

- *Les générateurs de données* permettent de charger les images par lots (batches) plutôt que toutes en même temps, ce qui est particulièrement utile lorsque l'on travaille avec de grands datasets qui ne tiennent pas en mémoire.
- Ils facilitent également l'application d'augmentations de données à la volée, ce qui enrichit le dataset d'entraînement.

2. Configuration des Générateurs

- *Train Generator* : Utilisé pour l'entraînement du modèle, ce générateur applique des transformations aléatoires aux images pour augmenter la diversité du dataset (rotation, translation, zoom, etc.).
- *Validation Generator* : Utilisé pour évaluer les performances du modèle pendant l'entraînement, ce générateur applique uniquement la normalisation des images (pas d'augmentations) pour fournir une évaluation précise et non biaisée.
- *Test Generator* : Utilisé après l'entraînement pour évaluer les performances finales du modèle sur un ensemble de test.

3. Paramètres de Compilation du Modèle

- *Optimiseur*
 - **Adam** : Choisi pour sa capacité à ajuster les taux d'apprentissage pour chaque paramètre individuellement. Il combine les avantages des optimiseurs AdaGrad et RMSProp et est généralement plus performant sur une large gamme de tâches.
- *Fonction de Perte*
 - **Categorical Crossentropy** : Utilisée pour les tâches de classification multi-classes. Elle mesure la distance entre la distribution de probabilité prédite par le modèle et la distribution réelle des classes.

- *Métriques*

- **Accuracy** : Choisie comme métrique principale car elle donne une bonne indication de la performance globale du modèle en termes de classification correcte des signes. Elle représente le pourcentage de prédictions correctes par rapport au nombre total de prédictions.

4. Stratégies de Régularisation

- La régularisation est essentielle pour prévenir le surapprentissage (overfitting), où le modèle mémorise les données d'entraînement au lieu d'apprendre à généraliser.
- *Techniques Utilisées*
 - **Dropout et L2 régularisation** : Comme vu précédemment prévient le sur-apprentissage
 - **BatchNormalization** : Normalise les activations de chaque couche pour stabiliser et accélérer l'entraînement, tout en ayant un effet régularisateur.

6.4.2 Processus d'Entraînement

1. Algorithme d'Entraînement

- *Description Générale* : L'entraînement du modèle implique de passer en revue l'ensemble des données d'entraînement par lots (batches) sur plusieurs époques (epochs), 50 exactement. À chaque époque, le modèle ajuste ses poids pour minimiser la fonction de perte.
- *Callbacks*
 - **Early Stopping** : Arrête l'entraînement si la performance sur l'ensemble de validation cesse de s'améliorer pendant un nombre défini d'époques (patience). Cela prévient le surapprentissage en arrêtant l'entraînement avant que le modèle ne commence à suradapter les données d'entraînement.
 - **Model Checkpoint** : Sauvegarde le modèle à chaque époque où la performance sur l'ensemble de validation s'améliore. Cela garantit de conserver le meilleur modèle trouvé pendant l'entraînement.

2. Stratégie de Gel des Couches pour les modèles de TL

- *Description des Stratégies* : L'expérience implique de tester quatre stratégies de gel des couches pour évaluer leur impact sur la performance du modèle :
 - **All** : Stratégie par défaut, toutes les couches du modèle sont gelées, donc tous les poids sont conservés.
 - **First** : Les premières couches du modèle sont entraînées tandis que les autres sont gelées. Cette stratégie permet de conserver les caractéristiques générales apprises par les premières couches tout en adaptant les couches initiales aux spécificités du nouveau dataset.
 - **Middle** : Les couches intermédiaires sont entraînées tandis que les premières et les dernières couches sont gelées. Cela permet d'adapter les couches intermédiaires tout en conservant les caractéristiques de bas et de haut niveau des couches initiales et finales.
 - **Last** : Les dernières couches sont entraînées tandis que les premières et les intermédiaires sont gelées. Cette stratégie permet d'adapter les caractéristiques de haut niveau aux spécificités du nouveau dataset.

- *Mise en Œuvre* : Pour chaque stratégie, les couches sélectionnées sont dégelées et entraînées sur le dataset de signes LSF. Les performances des modèles sont ensuite comparées pour déterminer quelle stratégie offre la meilleure précision, la plus faible perte et la meilleure stabilité.

3. Validation croisée

- La validation croisée (cross-validation) est utilisée pour évaluer la robustesse et la stabilité du modèle. Elle consiste à diviser le dataset en plusieurs parties (folds), dans notre cas 5 folds (ainsi 20% soit un cinquième du dataset sert à la validation), elle consiste à entraîner le modèle sur une combinaison de ces parties et à valider sur la partie restante.
- Le dataset étant relativement petit, le choix de 5 folds pour la validation croisée permet d'assurer un équilibre optimal entre la quantité de données disponibles pour l'entraînement et la validation. Avec 5 folds, chaque fold contient une proportion suffisante de données pour que le modèle puisse apprendre efficacement, tout en permettant une évaluation robuste et fiable de ses performances sur des ensembles de validation distincts. Cela permet aussi de maintenir un coût d'entraînement raisonnable. Le code est disponible dans [Annexe 1].
- *Processus*
 - **Stratified K-Fold Cross-Validation** : Cette technique assure que chaque fold contient approximativement la même proportion de chaque classe, ce qui est crucial pour éviter les biais de classe.
 - **Evaluation Multiple** : Le modèle est entraîné et évalué 5 fois (une fois par fold), et les résultats sont agrégés pour fournir une estimation plus fiable de la performance du modèle. Si la variation des scores des différents folds est négligeable alors on considère le modèle robuste et validé. Cela permet aussi d'assurer que chaque partie du dataset est utilisée pour l'entraînement et la validation.

L'entraînement du modèle est soigneusement configuré pour maximiser les performances tout en minimisant les risques de surapprentissage. L'utilisation de générateurs de données permet une gestion efficace de la mémoire et une augmentation dynamique des données. Les stratégies de régularisation telles que Dropout, L2 Regularization et BatchNormalization jouent un rôle clé dans l'amélioration de la capacité de généralisation du modèle. Enfin, la validation croisée est utilisée pour évaluer la robustesse du modèle, garantissant ainsi des performances fiables et reproductibles.

6.5 Évaluation, validation et résultat

6.5.1 Évaluation du Modèle

Métriques d'évaluation utilisées :

1. **Accuracy (Précision)** : La précision est la proportion d'instances correctement classées par le modèle parmi toutes les instances. Elle est calculée comme le rapport du nombre de prédictions correctes au nombre total de prédictions. La précision est une métrique essentielle pour les tâches de classification multi-classes, car elle donne une idée globale de la performance du modèle. Une haute précision indique que le modèle fait peu d'erreurs de classification.

2. **Loss (Perte)** : La perte est une mesure de l'erreur du modèle. Dans le contexte de la classification multi-classes, la perte de cross-entropy catégorielle est souvent utilisée. Elle quantifie la différence entre les prédictions du modèle et les étiquettes réelles. Minimiser la perte est crucial car cela signifie que le modèle s'ajuste bien aux données d'entraînement sans trop d'erreurs. Une perte faible est généralement associée à une meilleure performance du modèle.
3. **Recall (Rappel)** : Le rappel est la capacité du modèle à identifier toutes les instances positives d'une classe donnée. Il est calculé comme le rapport du nombre de vrais positifs au nombre total de vrais positifs et de faux négatifs. Un rappel élevé indique que le modèle ne manque pas beaucoup d'exemples de la classe.
4. **F1-Score** : Le F1-score est la moyenne harmonique de la précision et du rappel. Il offre un équilibre entre ces deux métriques, particulièrement utile lorsque les classes sont déséquilibrées. Un F1-score élevé indique que le modèle a à la fois une bonne précision et un bon rappel.

6.5.2 Résultats obtenus sur l'ensemble de test

Après l'entraînement, le modèle est évalué sur un ensemble de test indépendant. Les métriques de précision et de perte sont calculées pour cet ensemble, fournissant une évaluation de la performance du modèle sur des données qu'il n'a jamais vues.

Résultat du modèle de référence CNN

Pour le modèle de référence **CNN** on a cherché à comparer les performances du modèle en utilisant des images en couleurs (RGB) et en niveaux de gris (Grayscale) afin d'évaluer l'impact de la réduction de la complexité des données d'entrée sur les performances du modèle. Les images RGB contiennent trois canaux de couleur (rouge, vert, bleu), fournissant ainsi des informations visuelles plus riches que les images en niveaux de gris, qui ne contiennent qu'un seul canal.

Mode de couleur	Accuracy	Loss
RGB	80%	2.46
GRAYSCALE (niveau de gris)	78.2%	2.68

TABLE 6.3 – Résultats du modèle de référence **CNN** en fonction de différents modes de couleurs

La table 6.3 montre les performances du modèle CNN sur des images de couleurs ou sur des images avec un filtre gris. Les images RGB fournissent une performance légèrement plus importante, la différence n'est pas extrêmement marquée, ce qui suggère que les informations structurelles des signes qui sont présentes dans les images en niveaux de gris, sont également très importantes pour la tâche de reconnaissance.

Résultats pour l'ensemble des stratégies d'entraînements appliqué au deux modèles VGG16 et MobileNetV2

Modèle	Stratégie	Précision (%)	Perte
VGG16	All	95.5	0.14
	First	99.1	0.03
	Middle	99.8	0.01
	Last	4.8	3.04
MobileNetV2	All	99.8	0.14
	First	90.03	0.29
	Middle	100.00	0.01
	Last	84.52	0.54

TABLE 6.4 – Résultats des Modèles avec Différentes Stratégies de Gel des Couches

La Table 6.4 donne les résultats après l'évaluation sur l'ensemble de test des différents entraînements pour chaque stratégie appliquées aux deux modèles VGG16 et MobileNetV2. Les résultats obtenus montrent que les différentes stratégies de gel des couches ont un impact significatif sur les performances des deux modèles.

— VGG16 :

- Avec la stratégie **All**, le modèle atteint une précision de 95.5% et une perte de 0.14. Cela montre une bonne performance globale avec cette approche.
- La stratégie **First** donne une précision très élevée de 99.1% et une perte de 0.03, indiquant que le modèle bénéficie de la formation des couches intermédiaires et finales.
- La stratégie **Middle** atteint la meilleure précision de 99.8% avec une perte très faible de 0.01, ce qui suggère que les couches intermédiaires jouent un rôle crucial dans l'apprentissage des caractéristiques.
- La stratégie **Last** est la moins performante avec une précision de seulement 4.8% et une perte élevée de 3.04, indiquant que les dernières couches sont essentielles pour la tâche de classification. Le callback Early Stopping a arrêté l'entraînement au bout de 11ème époque car la performance de l'ensemble de validation n'a pas cessé de se dégrader, le modèle n'arrivait pas à se généraliser aux données de validation.

— MobileNetV2 :

- Avec la stratégie **All**, le modèle atteint une précision de 99.8% et une perte de 0.14, ce qui montre une très bonne performance globale.
- La stratégie **First** donne une précision de 90.03% et une perte de 0.29, indiquant une performance raisonnable mais inférieure à la précédente stratégie.
- La stratégie **Middle** atteint une précision parfaite de 100.0% avec une perte de 0.01, ce qui montre que les couches intermédiaires sont essentielles pour ce modèle.
- La stratégie **Last** donne une précision de 84.52% avec une perte de 0.54, ce qui montre une performance nettement inférieure, soulignant l'importance des dernières couches pour ce modèle. De plus, l'entraînement a été arrêté par le callback early stopping à la 20ème époque, ce qui montre que le modèle avait cessé de s'améliorer de manière significative au-delà de ce point.

En termes de coût d'entraînement et de stabilité du modèle, nous avons finalement choisi la stratégie **All**. Cette stratégie permet d'obtenir des performances globalement bonnes tout en garantissant une stabilité pendant l'entraînement. Nous avons constaté que, pour les autres stratégies, les scores sur l'ensemble de validation étaient souvent inférieurs aux scores d'entraînement.

En d'autres termes, le modèle devient excellent pour prédire les échantillons d'entraînement mais échoue à bien performer sur des données non connues. Cela est indiqué par les écarts significatifs entre les performances d'entraînement (par exemple, 95%) et les performances de validation (par exemple, 75%). Les grandes différences entre ces scores montrent que le modèle ne se généralise pas bien et qu'il est trop ajusté aux données d'entraînement.

La stratégie **All** est préférée parce qu'elle offre des performances globalement bonnes et stables à la fois sur les données d'entraînement et de validation, minimisant ainsi le risque de surapprentissage. **C'est donc la stratégie All qui a été utilisée pour la suite de l'expérimentation.**

Résultats du modèle MobileNetV2 selon différentes dimensions

Le modèle **MobileNetV2** étant en capacité d'accepter des images de dimensions importantes, 224x224 pixels, avec un coût d'entraînement raisonnable, on a décidé de réaliser deux entraînements avec des images de dimensions différentes afin d'observer l'impact.

Dimensions (pixels)	Accuracy	Loss
64x64	92%	0.22
224x224	99.8%	0.02

TABLE 6.5 – Résultats du modèle **MobileNetV2** en fonction de différentes dimensions

La Table 6.5 montre les résultats du modèle MobileNetV2 sur deux set de dimensions différents. On observe que sur des images de dimension 64x64, il a obtenu un score de 92% pour une perte de 0.22, alors que sur des images de dimensions 224x224 il obtient un score bien plus performant, de 99.8% et une perte de 0.02. **MobileNetV2 est normalement entraîné sur des images de dimension 224x224, ce qui peut contribuer à sa meilleure performance.** Les images de plus grande taille contiennent plus d'informations, permettant au modèle de capturer des caractéristiques plus détaillées.

Les meilleurs résultats pour l'ensemble des modèles

Dans la Table 6.6 on observe les meilleurs résultats de tous les modèles entraînés :

Model	Accuracy	Loss	F1-Score	Recall
CNN	80%	2.46	77%	80%
VGG16	95%	0.14	95%	95%
MobileNetV2	99.8%	0.02	99.8%	99.8%

TABLE 6.6 – Résultats globaux de l'ensemble des modèles sur l'ensemble de test

MobileNetV2 est le modèle le plus performant avec une précision, un recall et un F1-score de 99.8% et une perte de 0.02. Cela indique une excellente capacité à classer

correctement les images, avec très peu d'erreurs.

VGG16 suit avec une précision de 95% et une perte de 0.14, ce qui est également très bon, mais légèrement inférieur à MobileNetV2.

Le modèle de référence CNN montre une performance acceptable avec une précision de 80% et une perte de 2.46, mais nettement inférieure aux modèles pré-entraînés. De plus, on a pu observer des tendances au sur-apprentissage.

Ces résultats nous permettent d'observer que les modèles pré-entraînés sur Image-Net sont très performants et que le transfert de connaissances est bien réalisé, **mais aussi que la taille des images joue un rôle cruciale**. Cela sera confirmé avec la validation croisée.

6.5.3 Visualisation des performances

Courbes d'Apprentissage (Accuracy, Loss) :

CNN




FIGURE 6.2 – Représentation des courbes de précision et de perte

La Figure 6.2 présente la courbe de précision (à gauche) :

- Au début de l'entraînement, la précision sur l'ensemble d'entraînement (courbe bleue) augmente de manière constante, passant d'environ 0.1 à plus de 0.7. Cela indique que le modèle apprend bien sur les données d'entraînement.
- La précision sur l'ensemble de validation (courbe rouge) est beaucoup plus volatile, avec des fluctuations importantes. Cette instabilité suggère que le modèle peut avoir des difficultés à généraliser, ce qui pourrait être dû à un surapprentissage.

La Figure 6.2 présente la courbe de perte (à droite) :

- La perte sur l'ensemble d'entraînement (courbe bleue) diminue régulièrement, passant de plus de 16 à environ 2, ce qui montre que le modèle réduit bien son erreur sur les données d'entraînement.

- La perte sur l'ensemble de validation (courbe rouge) suit une tendance similaire mais est plus erratique, avec de grandes fluctuations. Elle commence à un niveau élevé (environ 16), diminue rapidement, puis fluctue de manière significative autour de la valeur de 2.

La grande différence entre la courbe de perte de l'entraînement et celle de la validation, ainsi que les fluctuations importantes de la perte de validation, indiquent un possible surapprentissage. Le modèle s'ajuste trop aux données d'entraînement et n'arrive pas à bien généraliser sur les données de validation.

Cela peut s'expliquer par le dataset pauvre que l'on a créé.

VGG16 et MobileNetV2




FIGURE 6.3 – Représentation des courbes de précision et de perte du modèle VGG16




FIGURE 6.4 – Représentation des courbes de précision et de perte du modèle MobileNetV2

Les Figures 6.3, et 6.4 présente les courbes de précision des respectives des modèles VGG16 et MobileNetV2 (à gauche pour chaque graphique) :

La précision sur l'ensemble d'entraînement (courbe bleue) augmente de manière constante au fur et à mesure des epochs, passant d'environ 0.1 à 0.75 pour le modèle VGG16 et de 0.1 à 0.95 pour MobileNetV2. Cela indique que le modèle apprend bien sur les données d'entraînement. La précision sur l'ensemble de validation (courbe rouge) commence également par une forte augmentation, atteignant rapidement des valeurs élevées autour de 0.8 à 0.95 pour VGG16 et 0.9 à 1 pour MobileNetV2, dès les premières

epochs. On observe une stabilisation qui suggère que le modèle a atteint un bon niveau de généralisation.

Les Figures 6.3, et 6.4 présente les courbes de perte des respectives des modèles VGG16 et MobileNetV2 (à gauche pour chaque graphique) :

La perte sur l'ensemble d'entraînement (courbe bleue) diminue de manière régulière, passant de 3 à environ 0.5 pour VGG16 et 2.5 à 0.25 pour MobileNetV2. Cela montre que les deux modèles réduisent efficacement leur erreur sur les données d'entraînement. La perte sur l'ensemble de validation (courbe rouge) suit une tendance similaire, diminuant rapidement au début, puis se stabilisant autour de valeurs inférieures à 0.5 pour les deux modèles, en remarquant que le modèle MobileNetV2 a une perte qui tend de manière très proche de 0. Les deux courbes de perte de validation sont constamment inférieures aux courbes de perte d'entraînement, ce qui est généralement un bon signe de généralisation. Les modèles ne semblent pas surapprendre les données d'entraînement, car la perte de validation ne remonte pas et reste inférieure à celle de l'entraînement.

Matrices de confusion pour analyser les erreurs de classification :

CNN




FIGURE 6.5 – Représentation de la matrice de confusion du modèle CNN

La Figure 6.5 montre la matrice de confusion du modèle CNN. La diagonale principale représente les prédictions correctes où la classe prédite correspond à la classe

réelle. La majorité des prédictions correctes se trouvent le long de cette diagonale, ce qui est un signe positif de la performance du modèle. La majorité des classes ont des prédictions assez précises proche de 32 soit le nombre d'images par classe. On remarque tout de même que quelques classes ont des performances moindres comme les classes C, F, V qui ont des prédictions proches de 20, la classe F est souvent confondue avec la classe T (13 prédictions incorrectes) ce qui peut avoir un certain sens car ces signes sont très ressemblants. Certaines classes ont des distributions plus éparpillées comme la classe G avec 11 prédictions correctes et des fortes confusions avec la classe I (20 prédictions incorrectes). Le plus flagrant est la classe R qui n'est jamais reconnue et est totalement confondue avec la classe U, ces deux signes ayant une certaine similarité.

Le modèle a des résultats satisfaisants mais possède des lacunes pour certaines classes, cela est sûrement dû au manque de données, qui permettraient une meilleure distinction entre les signes similaires.

VGG16 et MobileNetV2




FIGURE 6.6 – Représentation de la matrice de confusion du modèle VGG16




FIGURE 6.7 – Représentation de la matrice de confusion du modèle MobileNetV2

Pour les modèles VGG16 et MobileNetV2 les prédictions sont très précises, seuls les classes T et W ont des performances moins importantes chez VGG16, la classe a 24 prédictions correctes et est confondue 8 fois avec la classe F, ce qui semble explicable vu la ressemblance des signes, de même pour la classe W qui est confondue avec les classes V et H.

Quant au modèle MobileNetV2 les prédictions sont toutes parfaites pour toutes les classes hormis la classe F qui est seulement confondue une fois avec la classe T.

Pour ces deux modèles les performances sont excellentes, les quelques erreurs observées sont minimales. Les résultats suggèrent que ces deux modèles sont bien adaptés à cette tâche qu'est la reconnaissance et pourraient être utilisés de manière fiable pour la reconnaissance de signes en temps réel.

Résultat validation croisée :

Processus de validation croisée

La validation croisée assure que le modèle est évalué sur différentes partitions du dataset, réduisant le risque de surapprentissage et fournissant une évaluation plus robuste de la performance. En moyenne, les résultats des K folds donnent une estimation plus fiable de la performance du modèle sur des données non vues.

VGG16

Fold	Accuracy (%)	Loss
1	93.6	0.28
2	93.9	0.25
3	94.3	0.27
4	93.5	0.25
5	92.9	0.28

TABLE 6.7 – Résultats de la validation croisée pour VGG16

Les précisions des cinq folds sont très proches, variant entre 92.9 et 94.3. La faible variation des précisions indique que le modèle VGG16 est robuste et stable, fournissant des performances cohérentes sur différents sous-ensembles de données. Cela suggère que le modèle est bien généralisé et ne dépend pas fortement d'un ensemble spécifique de données pour atteindre une haute performance.

Les pertes varient aussi très peu, allant de 0.25 à 0.28. Bien que la perte fluctue légèrement, elle reste relativement basse dans tous les folds, indiquant que le modèle apprend bien les caractéristiques des données.

Les résultats de VGG16 montrent une bonne capacité de généralisation et des performances stables sur différents sous-ensembles de données, avec une précision élevée et une perte relativement faible. Cela confirme que VGG16 est un modèle performant pour cette tâche.

MobileNetV2

Fold	Accuracy (%)	Loss
1	99.8	0.01
2	99.6	0.01
3	99.6	0.01
4	99.6	0.01
5	99.8	0.01

TABLE 6.8 – Résultats de la validation croisée pour MobileNetV2

Les précisions des trois folds sont uniformément à plus de 99%. La constance des précisions montre que MobileNetV2 est extrêmement fiable et performant. La précision quasi parfaite dans tous les folds indique une excellente capacité de généralisation et une robustesse exceptionnelle du modèle.

Les pertes sont également uniformes à 0.01 dans tous les folds. La perte très basse et constante indique que le modèle a appris les caractéristiques des données de manière très efficace, avec peu d'erreurs de prédiction. Cela montre que MobileNetV2 non seulement atteint une haute précision, mais le fait avec une très faible marge d'erreur.

L'analyse des résultats de validation croisée montre que MobileNetV2 est le modèle le plus performant et le plus robuste pour la tâche de reconnaissance des signes, surpassant VGG16 en termes de précision et de perte. Ces résultats indiquent que MobileNetV2 peut être déployé avec confiance pour des applications pratiques, offrant une excellente capacité de généralisation et des performances fiables.

Conclusion

L'évaluation et la validation sont des étapes cruciales pour assurer que le modèle est performant et généralisable. En utilisant des métriques appropriées, la validation croisée, et des outils de visualisation comme les courbes d'apprentissage et les matrices de confusion, nous pouvons obtenir une compréhension approfondie des capacités et des limitations du modèle. Cela nous permet de faire des ajustements éclairés pour améliorer la performance globale et assurer une robustesse maximale.

6.6 Application en temps réel

6.6.1 Description de l'interface utilisateur avec Streamlit

Streamlit est une bibliothèque Python open-source qui permet de créer facilement des applications web interactives pour l'apprentissage automatique et la science des données. Elle est simple à utiliser et ne nécessite pas de connaissances approfondies en développement web. Streamlit offre une intégration transparente avec les modèles de machine learning, une interactivité en temps réel et un déploiement facile sur des plateformes cloud comme Streamlit Sharing.

La Figure 6.8 montre l'interface utilisateur. L'interface utilisateur est conçue pour être intuitive et conviviale, avec un bouton pour démarrer et arrêter la prédiction en temps réel. Utilisation de la bibliothèque OpenCV pour capturer et afficher le flux vidéo de la webcam en temps réel. Les prédictions du modèle, y compris le signe prédit et sa probabilité, sont affichées directement sur le flux vidéo pour une visualisation immédiate.



FIGURE 6.8 – Représentation de l'interface utilisateur, prédiction du signe B

6.6.2 Intégration du modèle pour la prédiction en temps réel

Le modèle de reconnaissance des signes le plus performant, soit MobileNetV2, préalablement entraîné, est chargé au démarrage de l'application. La bibliothèque OpenCV est utilisée pour accéder à la webcam de l'utilisateur et capturer le flux vidéo en temps réel. Chaque image capturée est prétraitée (redimensionnement, normalisation) avant d'être passée au modèle pour la prédiction.

6.6.3 Traitement des images en temps réel

La détection et le recadrage de la main ont été réalisés avec la bibliothèque MediaPipe. MediaPipe est une bibliothèque développée par Google qui offre des solutions robustes pour la détection et le suivi de la main en temps réel. Elle est optimisée pour la performance et la précision. Cette bibliothèque fournit des points de repère précis pour les mains, ce qui permet de détecter et de recadrer la région d'intérêt (la main, le bras) de manière efficace.

Processus de détection :

- **Capture des points de repère :** MediaPipe est utilisé pour détecter les points de repère de la main dans chaque image capturée.
- **Calcul des coordonnées de recadrage :** Les coordonnées des points de repère sont utilisées pour calculer une boîte englobante autour de la main.
- **Recadrage de l'image :** L'image est recadrée pour se concentrer sur la main avant d'être redimensionnée et normalisée pour la prédiction par le modèle.

6.6.4 Prédiction du signe et affichage des résultats en temps réel

L'image recadrée de la main est redimensionnée aux dimensions d'entrée du modèle, dans ce cas-là 224x224 pixels pour MobileNetV2. Elle est ensuite normalisée et passée au modèle qui effectue une prédiction sur celle-ci dans le but d'identifier le signe. Une matrice nous est retournée par le modèle avec la probabilité pour chaque classe associée. On récupère la classe/la lettre avec la probabilité la plus élevée et on affiche à la fois la lettre et la probabilité qu'il s'agisse bien du signe effectué sur le flux vidéo en temps réel. Cela permet à l'utilisateur de voir immédiatement les résultats de la prédiction.

6.6.5 Résultat en utilisant l'Application

La plupart des signes sont reconnus assez facilement, certaines lettres cependant sont difficilement reconnaissables, tels que le M, le F et le T qui sont très ressemblants. Le plus probable est que les conditions de l'entraînement, de la construction du dataset et de la prise en direct du flux vidéo sont assez différentes. Le dataset a été construit grâce à la caméra arrière d'un téléphone, une caméra de 12MP (mégapixels), donc une bonne qualité de photo avec beaucoup de détails, avec un ajustement du flou réalisé par le téléphone.

Quant à la prise vidéo en continu, elle a été réalisée par la webcam d'un ordinateur, qui possède une caméra beaucoup moins qualitative, de plus elle ne possède pas les ajustements que peut offrir une caméra de téléphone. Le résultat reste tout de même intéressant au vu de toutes ces conditions.

Cette application permet une interaction intuitive et immédiate avec le système de reconnaissance des signes, offrant une solution efficace et pratique pour la recon-

naissance des signes en temps réel. Elle permet de jouer un rôle éducatif, en facilitant l'apprentissage de certains signes auprès des différents utilisateurs.

Chapitre 7

Conclusion et perspectives

Ce mémoire a exploré l'application du transfert d'apprentissage pour la reconnaissance de l'alphabet LSF. Nous avons suivi une méthodologie structurée qui comprenait la préparation d'un dataset, la conception et l'entraînement de modèles (en suivant différentes stratégies et combinaisons de couleurs ou de dimensions selon les capacités de chaque modèle), l'évaluation et la validation des modèles, ainsi que le développement d'une application en temps réel. Notre approche a permis d'obtenir des résultats prometteurs, notamment grâce à l'utilisation de modèles pré-entraînés comme VGG16 et MobileNetV2, et à l'application de techniques d'augmentation des données pour enrichir le dataset et améliorer la généralisation du modèle.

Cependant, notre travail présente certaines limitations. La taille initiale du dataset est relativement petite, ce qui peut limiter la capacité du modèle à généraliser sur de nouvelles données. De plus, le dataset manque de variabilité en termes de conditions de prise de vue, ce qui peut affecter les performances du modèle en conditions réelles.

Pour l'avenir, plusieurs pistes d'amélioration sont envisageables. Il serait bénéfique de collecter un dataset plus vaste et plus diversifié, incluant différentes conditions d'éclairage, arrière-plans et variations de signeurs. Explorer d'autres modèles pré-entraînés plus récents ou spécialisés dans la reconnaissance gestuelle pourrait également améliorer les performances. Améliorer les techniques de prétraitement des images, telles que la normalisation des couleurs et la suppression des arrière-plans, pourrait réduire les biais et améliorer la robustesse du modèle. Le fait de pré-entraîner certains modèles sur des datasets plus spécifiques à la tâche qu'on souhaite réaliser (ici la reconnaissance des signes), comme la reconnaissance d'actions, ou peut être même pré-entraîner des modèles sur des tâches de reconnaissances de signes sur d'autres langues comme ASL ou ArSL qui ont des datasets beaucoup plus fournis pour voir si le transfer learning se réalise plus efficacement.

En outre, l'exploration de nouvelles techniques pourrait également apporter des bénéfices. Des architectures de réseaux neuronaux convolutifs plus profondes et plus sophistiquées pourraient capturer des caractéristiques plus complexes des signes. Intégrer des réseaux de neurones récurrents ou des modèles basés sur l'attention permettrait de capturer les séquences de mouvements dans la langue des signes. Enfin, explorer des approches de transfer learning multimodal, qui intègrent des données visuelles avec des données de capteurs de mouvement, pourrait offrir une reconnaissance plus précise des signes.

En résumé, ce mémoire a démontré la faisabilité de la reconnaissance l'alphabet LSF à l'aide de techniques de transfert learning. Les résultats obtenus sont prometteurs, mais des améliorations sont possibles en augmentant la taille et la diversité du dataset, en explorant de nouvelles architectures de modèles et en optimisant les hyperparamètres. Les perspectives futures incluent également l'adaptation des modèles pour des applications mobiles et l'exploration de techniques avancées pour améliorer encore la précision et la robustesse de la reconnaissance des signes.

Bibliographie

- [1] Weiss, K., Khoshgoftaar, T. M., & Wang, D. (2016). A survey of transfer learning. *Journal of Big Data*, 3(1), 9. <https://doi.org/10.1186/s40537-016-0043-6>
- [2] Rastgoo, R., Kiani, K., & Escalera, S. (2021). Sign Language Recognition : A Deep Survey. *Expert Systems with Applications*, 164, 113794. <https://doi.org/10.1016/j.eswa.2020.113794>
- [3] Pigou, L., Dieleman, S., Kindermans, P. J., & Schrauwen, B. (2014). Sign language recognition using convolutional neural networks. In *Proceedings of the European Conference on Computer Vision (ECCV) Workshops*.
- [4] Camgoz, N. C., Hadfield, S., Koller, O., & Bowden, R. (2020). Sign language transformers : Joint end-to-end sign language recognition and translation. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 10023–10033. Retrieved from http://openaccess.thecvf.com/content_CVPR_2020/html/Camgoz_Sign_Language_Transformers_Joint_End-to-End_Sign_Language_Recognition_and_Translation_CVPR_2020_paper.html
- [5] Adaloglou, N., Chatzis, T., Papastratis, I., Stergioulas, A., Papadopoulos, G. T., Zacharopoulou, V., ... & Daras, P. (2020). A Comprehensive Study on Deep Learning-Based Methods for Sign Language Recognition. *IEEE Transactions on Multimedia*, 24, 1750–1762. <https://ieeexplore.ieee.org/abstract/document/9393618/>
- [6] Perea-Trigo, M., Botella-López, C., Martínez-del-Amor, M. Á., Álvarez-García, J. A., Soria-Morillo, L. M., & Vegas-Olmos, J. J. (2024). Synthetic Corpus Generation for Deep Learning-Based Translation of Spanish Sign Language. *Sensors*, 24(5), 1472. Retrieved from <https://www.mdpi.com/1424-8220/24/5/1472>
- [7] Bragg, D., Koller, O., Bellard, M., Berke, L., Boudreault, P., Braffort, A., ... & Morris, M. R. (2019). Sign Language Recognition, Generation, and Translation : An Interdisciplinary Perspective. In *The 21st International ACM SIGACCESS Conference on Computers and Accessibility*, 16-31. <https://doi.org/10.1145/3308561.3353774>
- [8] Goel, L., Karthik, N. P., & Naidu, M. J. (2023). Real-Time Sign Language Recognition using Transfer Learning. Retrieved from <http://www.cse.griet.ac.in/pdfs/journals22-23/SC33.pdf>
- [9] Garcia, B., & Viesca, S. A. (2016). Real-time American Sign Language Recognition with Convolutional Neural Networks. In *Convolutional Neural Networks for Visual Recognition*, 225-232. Retrieved from http://vision.stanford.edu/teaching/cs231n/reports/2016/pdfs/214_Report.pdf
- [10] Zakariah, M., Alotaibi, Y. A., Koundal, D., Guo, Y., & Elahi, M. M. (2022). Sign language recognition for Arabic alphabets using transfer learning technique. *Computational Intelligence and Neuroscience*. Retrieved from <https://downloads.hindawi.com/archive/2022/4567989.pdf>

- [11] Sarhan, N., & Frintrop, S. (2023). Unraveling a Decade : A Comprehensive Survey on Isolated Sign Language Recognition. In *Proceedings of the IEEE/CVF International Conference on Computer Vision*, 3210–3219. Retrieved from https://openaccess.thecvf.com/content/ICCV2023W/AMFG/html/Sarhan_Unraveling_a_Decade_A_Comprehensive_Survey_on_Isolated_Sign_Language_ICCVW_2023_paper.html
- [12] Bilge, Y. C., Cinbis, R. G., & Ikizler-Cinbis, N. (2023). Towards Zero-shot Sign Language Recognition. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 45(1), 1217-1232. <https://doi.org/10.1109/TPAMI.2022.3143074>
- [13] Alzubaidi, L., Fadhel, M. A., Al-Shamma, O., Zhang, J., Santamaría, J., Duan, Y., & Oleiwi, S. R. (2020). Towards a Better Understanding of Transfer Learning for Medical Imaging : A Case Study. *Applied Sciences*, 10(13), 4523. <https://doi.org/10.3390/app10134523>

Webographie

[WEB 1] <https://www.un.org/fr/observances/sign-languages-day#:~:text=Selon%20la%20F%C3%A9d%C3%A9ration%20mondiale%20des,300%20langues%20des%20signes%20diff%C3%A9rentes.>

[WEB 2] <https://www.fnsf.org/>

[REPOSITORY APPLICATION] https://gitlab.com/lsf-slr-transfer-learning-project/slr_lsf_transfer_learning_app

[REPOSITORY DATASET] https://gitlab.com/lsf-slr-transfer-learning-project/slr_lsf_transfer_learning_dataset

[REPOSITORY TRAINING] https://gitlab.com/lsf-slr-transfer-learning-project/slr_lsf_transfer_learning_train

Chapitre 8

Annexes

Annexe .1 : Code Validation croisée

Listing 1 – Cross-validation model training and evaluation

```
import numpy as np
from sklearn.model_selection import StratifiedKFold
import pandas as pd
from tensorflow.keras.callbacks import EarlyStopping
import matplotlib.pyplot as plt

def cross_validate_model(create_model_func , train_datagen ,
validation_datagen , generator , target_size , epochs=30):
    # Recuperer les fichiers et les etiquettes de toutes
    les images de formation
    filepaths = np.array(generator.filepaths)
    labels = np.array(generator.classes)

    # Placeholder pour les scores de chaque fold
    fold_val_accuracies = []
    fold_val_losses = []

    # Definir StratifiedKFold avec 5 folds
    skf = StratifiedKFold(n_splits=5, shuffle=True, random_state=1)

    # Boucle sur chaque fold
    for train_index , val_index in skf.split(filepaths , labels):
        train_files = filepaths[train_index]
        val_files = filepaths[val_index]
        train_labels = labels[train_index].astype(str)
        val_labels = labels[val_index].astype(str)

        # Creer les generateurs pour le fold actuel
        train_fold_gen = train_datagen.flow_from_dataframe(
            dataframe=pd.DataFrame({'filename':
            train_files , 'class': train_labels}),
            directory=None,
            x_col='filename' ,
```

```

        y_col='class',
        target_size=target_size,
        batch_size=64,
        class_mode='categorical'
    )

    val_fold_gen = validation_datagen.flow_from_dataframe(
        dataframe=pd.DataFrame({'filename': val_files,
                                'class': val_labels}),
        directory=None,
        x_col='filename',
        y_col='class',
        target_size=target_size,
        batch_size=64,
        class_mode='categorical'
    )

    # Creer un nouveau modele pour chaque fold
    model_cv = create_model_func()

    # Callback pour Early Stopping
    early_stopping = EarlyStopping(monitor='val_loss',
                                    patience=10, restore_best_weights=True)

    # Entrainer le modele
    history = model_cv.fit(
        train_fold_gen,
        epochs=epochs,
        validation_data=val_fold_gen,
        callbacks=[early_stopping]
    )

    # Enregistrer les scores de validation
    best_val_accuracy = max(history.history['val_accuracy'])
    best_val_loss = min(history.history['val_loss'])
    fold_val_accuracies.append(best_val_accuracy)
    fold_val_losses.append(best_val_loss)

    print(f'Fold_validation_accuracy:_{best_val_accuracy:.4f}')
    print(f'Fold_validation_loss:_{best_val_loss:.4f}')

    # Afficher les resultats moyens de validation
    print(f'Mean_validation_accuracy:_{np.mean(fold_val_accuracies):.4f}')
    print(f'Mean_validation_loss:_{np.mean(fold_val_losses):.4f}')
    #plot_fold_acc_loss(fold_val_accuracies, fold_val_losses)
    print(f'acc_all_folders_{fold_val_accuracies}')
    print(f'loss_all_folders_{fold_val_losses}')

```